

SLM 개론 — SLM과 온프레미스 LLM 중요성

경량 거대언어모델의 실무 활용과 파인튜닝 전략

비용·보안·커스터마이징 한계를 극복하는 sLLM 솔루션

AI 교육 과정 |

목차

LLM API의 실무 한계

- 비용 문제: 토큰 단위 종량제 과금
- 보안 문제: 데이터 외부 전송 필수
- 커스터마이징 한계: 모델 수정 불가
- API vs 온프레미스 비교

sLLM의 정의와 배경

- sLLM의 개념과 매개변수 규모
- 실용적 대안이 된 기술 발전
- 효율적 아키텍처와 양자화 기술
- 오픈소스 생태계의 성장

sLLM의 특징점과 활용 사례

- 하드웨어 부담 감소와 비용 효율성
- 도메인 특화 가능성
- 국내 기업 활용 사례
- 비용 구조와 손익분기점 분석

파인튜닝 기법과 실무 적용

- 사전학습과 미세조정 흐름
- PEFT 기법 (LoRA/QLoRA)
- sLLM 생태계 소개
- 실무 파이프라인 구축 전략

학습 목표

LLM API 방식의 한계 이해

- 비용 측면: 토큰 단위 과금으로 인한 대규모 서비스 비용 급증
- 보안 측면: 데이터 외부 전송의 법적 제약
- 커스터마이징 측면: 모델 자체 수정 불가능

sLLM의 정의와 특징점

- sLLM은 LLM 구조를 유지하면서 규모를 줄인 경량 모델
- 수십억~수백억 개 매개변수로 효율적 운영
- 도메인 특화 시 충분한 성능 발휘

용어 구분 능력 습득

- SLM: 처음부터 소형으로 설계된 모델
- sLLM: LLM 아키텍처 기반 경량화 모델
- LLM: GPT-4, Claude 등 초거대 모델
- 실무에서의 용어 혼용 사례

파인튜닝의 필요성 설명

- sLLM은 경량화로 인한 범용 지식 부족
- PEFT(QLoRA)로 저비용 성능 보완
- 도메인 특화 학습의 중요성
- 실무 파이프라인 구축 방법

LLM API의 실무 한계



비용 문제: 쓸수록 돈이 나간다

- GPT-4o는 토큰 단위 종량제로 과금 (입력 \$2.50, 출력 \$10.00/1M 토큰)
- 소규모에서는 부담 없으나 규모 증가 시 비용 급증, 멀티턴 대화 시 2.5~3배 증가



보안 문제: 데이터를 밖으로 보내야 한다

- API 호출 시 데이터가 외부 서버로 전송됨
- 금융·의료·공공기관·법률·군사 분야에서 법적으로 데이터 외부 전송 불가능



커스터마이징 한계: 모델을 바꿀 수 없다

- API 모델은 사용자가 원하는 방향으로 수정 불가능
- 프롬프트 외에 모델 자체를 변경할 방법 없음, 도메인 특화 어려움

비용 문제 상세 분석

GPT-4o 과금 구조

- 입력 단가: \$2.50/1M 토큰
- 출력 단가: \$10.00/1M 토큰
- 높은 성능이지만 대량 처리 시 비용 부담
- 엔터프라이즈 서비스에서 비용 급증

GPT-4o-mini 과금 구조

- 입력 단가: \$0.15/1M 토큰
- 출력 단가: \$0.60/1M 토큰
- GPT-4o 대비 저렴하지만 여전히 종량제
- 소규모 서비스에 적합한 옵션

규모별 비용 증가 패턴

- 소규모(100건/일): 부담 없는 수준
- 중규모(1,000건/일): 월 수십만 원 발생
- 대규모(10,000건/일): 월 수백만 원 급증
- 처리량에 비례한 선형적 비용 증가

멀티턴 대화의 영향

- 이전 대화 전체를 매번 재전송 필요
- 3턴 평균 시 입력 토큰 3~4배 증가
- 실제 비용은 2.5~3배로 상승
- 대화형 서비스에서 비용 예측 어려움

법률 Q&A 서비스 비용 예시

기준 설정

- 질문: 200토큰
- 시스템 프롬프트: 300토큰
- 답변: 500토큰
- 총 1,000토큰/건

일일 100건

- GPT-4o: 월 3만 원
- GPT-4o-mini: 월 2천 원
- 소규모 서비스 적합
- 부담 없는 비용 수준

일일 1,000건

- GPT-4o: 월 26만 원
- GPT-4o-mini: 월 1.6만 원
- 중규모 서비스 수준
- 비용 관리 필요 시작

일일 10,000건

- GPT-4o: 월 260만 원
- GPT-4o-mini: 월 16만 원
- 대규모 서비스 수준
- 자체 모델 검토 필요

비용 증가 요인

- 멀티턴 대화 시 비용 2.5~3배 증가
- 이전 대화 재전송 필수
- 실제 비용 예측 어려움
- 온프레미스 전환 고려

보안 문제: 데이터를 밖으로 보내야 한다

API 호출 시 데이터 외부 전송

- API를 호출하면 데이터가 외부 서버로 전송됨
- 금융, 의료, 공공기관, 법률, 군사 분야에서 문제 발생
- 데이터 외부 전송 자체가 불가능한 환경 존재

규제 산업의 법적 제약

- 금융: 신용정보법, 데이터 관리 가이드라인
- 의료: 개인정보보호법, 의료법
- 공공기관: 국가정보원 보안 규정
- 법률: 변호사법, 비밀유지 의무

관련 법규 및 규정

- 신용정보법: 금융 데이터 외부 전송 금지
- 개인정보보호법: 민감 정보 보호 의무
- 국가정보원 보안 규정: 공공 데이터 보안
- 변호사법: 고객 정보 비밀 유지

데이터 보안의 중요성

- 데이터 유출 시 법적 책임 발생
- 기업 신뢰도 하락 및 손해배상 위험
- 규제 위반 시 영업 정지 가능성
- 온프레미스 솔루션이 유일한 대안

커스터마이징 한계와 API vs 온프레미스 비교



클라우드 API (GPT-4o)

- 성능 최상: 최신 기술 적용
- 셋업 불필요: 즉시 사용 가능
- 비용: 토큰당 과금, 대량 사용 시 급증
- 보안: 민감 데이터 외부 전송 필수
- 커스터마이징 불가: 모델 자체 수정 불가능
- 서비스 장애 및 정책 변경 리스크
- 프롬프트 외 모델 변경 방법 없음



온프레미스 sLLM

- 데이터 보안: 내부 서버에서 처리
- 반복 호출 비용 0원: 고정 비용 구조
 - 도메인 특화 파인튜닝 가능
 - 규제 산업 대응 가능
 - 초기 GPU 투자 필요
- 초기 셋업 및 학습 시간 필요
- 우리 데이터로 맞춤형 모델 구축

sLLM이란 무엇인가?

sLLM의 정의

- small Large Language Model의 약자
- LLM의 구조와 능력을 유지하면서 규모를 줄인 모델
- 경량 거대언어모델로 불림
- 적은 리소스로 훈련 가능

매개변수 규모

- 수십억~수백억 개의 매개변수
- LLM 대비 1/10 ~ 1/100 수준
- GPT-4는 수천억 개 이상
- 효율적인 크기로 설계됨

효율성과 성능

- LLM에 뒤지지 않는 효율 제공
- 특정 도메인에서 우수한 성능
- 빠른 추론 속도
- 낮은 운영 비용

최근 트렌드

- 범용보다 도메인 특화 모델 주목
- 기업 맞춤형 sLLM 개발 증가
- 온프레미스 배포 확대
- 보안과 비용 효율성 강조

sLLM이 실용적 대안이 된 배경

효율적 아키텍처

- Grouped Query Attention 적용
- Flash Attention으로 속도 향상
 - 적은 파라미터로 높은 성능
 - 메모리 효율성 개선

데이터 품질 연구

- 데이터 양보다 품질이 중요
- Chinchilla 연구 결과 반영
- Phi 시리즈의 성공 사례
- 고품질 데이터로 성능 향상

양자화 기술

- 4-bit 양자화 기술 발전
- 일반 GPU에서 실행 가능
- 메모리 사용량 대폭 감소
 - 추론 속도 향상

PEFT 기법

- LoRA 등 효율적 학습 기법
- 전체 파라미터의 0.1~1%만 학습
 - 빠른 파인튜닝 가능
 - 낮은 비용으로 특화 가능

오픈소스 생태계

- Meta의 LLaMA 공개
- Google의 Gemma 시리즈
 - LG의 EXAONE 모델
- 기업들의 적극적 모델 공개

sLLM 활용 사례 (1) - 도메인 특화형

업스테이지 솔라 미니

- 법률, 의료, 금융 등 전문 분야 특화
 - 전문 용어 정확도 향상
 - 도메인 맥락 이해 능력
- 범용 LLM 대비 정확한 답변
 - 업계 특화 데이터 학습

올거나이즈 알리 파이낸스

- 금융권 데이터 기반 학습
 - 금융 특화 언어모델
- 약관 분석 및 리스크 평가
 - 금융 규제 준수
- 정확한 금융 상품 설명

파수 엘름(Elm)

- 코딩, 세무, 금융 등 다직군 대응
 - 다산업 적용 가능한 모델
 - 기업 업무 자동화 지원
 - 전문 지식 기반 답변
 - 산업별 맞춤형 솔루션

도메인 특화의 핵심 가치

- 특정 산업 전문 용어 학습
 - 맥락을 깊이 이해
- 범용 모델보다 정확한 답변
 - 업무 효율성 향상
 - 신뢰도 높은 결과 제공

sLLM 활용 사례 (2) - 기업 내부 업무 자동화형 및 플랫폼형

삼성전자 Code.ISR

- 사내 코드 데이터 학습·활용
- 코드 생성으로 생산성 향상
- 외부 데이터 비노출로 안전
- 삼성 환경에 최적화

네이버 HCX-대시

- 문장 생성·요약 기능 제공
- 보고서 작성 자동화 지원
- 맞춤형 챗봇 구축 가능
- 네이버 내부 업무 효율화

스케터랩 Pingpong-1

- 관계지향 소형 대화 모델
- 사용자 경험·감성 대화 특화
- 일상 대화 품질 향상

SK C&C 솔루어 LLM옴스

- 기업 자체 sLLM 개발 가능
- 플랫폼·파인튜닝 도구 제공
- 맞춤형·기업 특화 모델 지원

sLLM의 특징점 (1) - 하드웨어와 비용

하드웨어 부담 감소

- 고가의 서버 구축 불필요
- 노트북, 스마트폰 등 엣지 디바이스 배포 가능
- GPU 필요 시에도 소규모로 충분
- 일반 GPU에서도 실행 가능

높은 비용 효율성

- 필요한 매개변수만 사용하여 학습 시간 단축
- 서버 자원 및 전력 등 운영 비용 절감
- 실험 비용 대폭 감소
- API 대비 반복 호출 비용 0원

빠른 실험 사이클

- 빠른 모델 훈련과 배포 가능
- 실험 사이클이 짧아짐
- 빠른 프로토타이핑 및 검증
- 도메인 적응 속도 향상

데이터 보안 및 맞춤형 구축

- 사내 데이터 활용한 맞춤형 모델 구축
- 데이터가 외부로 나가지 않아 유출 위험 감소
- 규제 산업 대응 가능
- 기업 특화 AI 개발 가능

sLLM의 특징점 (2) - 도메인 특화 가능성

법률 도메인

- 범용 LLM: 한국 법률·판례 지식 부족, 환각 발생
- sLLM 파인튜닝 효과: 법조항 인용 정확도 향상
- 답변 구조화 및 일관성 확보
- 대한민국 민법 등 특정 법률 근거 제시 가능

의료 도메인

- 범용 LLM: 의학 용어 오용, 위험한 조언 가능
- sLLM 파인튜닝 효과: 진료 가이드라인 준수
- 안전한 표현 사용
- 의료 전문 용어 정확도 향상

금융 도메인

- 범용 LLM: 금융 규제·상품 지식 불완전
- sLLM 파인튜닝 효과: 약관 분석 정확도 향상
- 리스크 평가 정확도 향상
- 금융 규제 준수 답변 생성

고객 상담 도메인

- 범용 LLM: 회사 정책·제품 정보 모름
- sLLM 파인튜닝 효과: 사내 FAQ 기반 정확한 안내
- 고객 문의 응대 품질 향상
- 회사 특화 지식 반영

sLLM 비용 구조와 손익분기점

무료 환경

- Colab T4: 초기 비용 0원, 월 유지비 0원
 - 학습 및 실험용으로 적합
 - 호출당 비용 0원
 - 제한된 사용 시간

개인 환경

- Colab Pro: 월 12,000원
 - 개인 프로젝트에 적합
 - 호출당 비용 0원
 - 안정적인 GPU 사용

소규모 서비스

- 클라우드 GPU(A100):
월 100~200만 원, 초기 부담 없음
소규모 서비스에 적합

대규모 서비스

- 자체 서버(A100 구매):
초기 3,000~5,000만 원, 월 10~30만 원
대규모 서비스 적합

손익분기점

- 일일 5,000건↑는 자체 모델 유리
- 비용·보안·커스터마이징 종합 판단

용어 정리: SLM vs sLLM vs LLM

SLM (Small Language Model)

- 소형언어모델
- 처음부터 소형으로 설계된 모델
- 경량 구조에 최적화
- 특정 용도에 맞춘 설계

sLLM (small Large Language Model)

- 경량거대언어모델
- LLM 아키텍처를 기반으로 경량화한 모델
- LLM의 구조와 능력 유지
- 매개변수 수십억~수백억 개 (LLM 대비 1/10~1/100)

LLM (Large Language Model)

- 대규모언어모델
- GPT-4, Claude 등 초거대 모델
- 매개변수 수천억~수조 개
- 최고 수준의 범용 성능

실무에서의 용어 사용

- SLM과 sLLM 용어가 혼용되는 경우 많음
- 본질적으로 경량화된 모델 지칭
- 실무에서는 맥락에 따라 구분
- 이번 과정에서는 sLLM 용어 사용

우리가 사용할 sLLM 생태계

EXAONE 3.5

- LG AI Research 개발
- 2.4B / 7.8B 파라미터
- 한국어 성능 우수 (★★★★★)
- 이번 과정의 주력 모델

LLaMA 3.2

- Meta 개발
- 1B / 3B 파라미터
- 범용, 영어 중심 (★★★)
- 글로벌 표준 모델

Gemma 2

- Google 개발
- 2B / 9B 파라미터
- 경량, 빠른 실험용 (★★★)
- 효율적인 아키텍처

Qwen 2.5

- Alibaba 개발
- 0.5B ~ 72B 파라미터
- 중국어·한국어 강세 (★★★★★)
- 다양한 크기 선택 가능

Phi-3

- Microsoft 개발
- 3.8B / 14B 파라미터
- 소형 모델 중 영어 최강 (★★)
- 고품질 데이터 학습

LLM 개발 및 미세조정 기법 흐름

사전학습 모델 (Pretrained)

- 범용 지식 습득 단계
- 웹 데이터 학습 (수조 토큰)
- 수천 GPU · 수개월 소요
- 비용 수십~수백억 원
- 파운데이션 모델 (Foundation Model)

미세조정 모델 (Fine-Tuned)

- 도메인 특화 단계
- 전체 Weight 변경
- 수만~수십만 건 데이터 학습
- 수십 GPU · 수일 소요
- 비용 수천만 원

PEFT 모델 (LoRA/QLoRA)

- 효율적 도메인 특화 단계
- 일부 파라미터만 변경 (전체의 0.1~1%)
- 수백~수천 건 데이터로 가능
- 1 GPU · 수시간 소요
- 비용 수만~수십만 원

PEFT의 실무 가치

- sLLM의 부족한 성능을 저비용으로 보완
- Colab 무료 T4로 실습 가능
- Full FT 대비 90~98% 성능
- 원본 모델 보존 (어댑터 분리)

sLLM과 파인튜닝의 중요성

sLLM의 한계

- 경량화로 인해 범용 지식이 LLM보다 부족
 - 특정 도메인 지식 보완 필요
- 파인튜닝을 통한 성능 향상 필수

파인튜닝의 역할

- sLLM의 부족한 성능을 보완하는 핵심 방법
 - 도메인 특화 데이터로 모델 적응
- 범용 모델의 한계 극복

Full Fine-tuning

- 모델 전체 파라미터 업데이트
 - A100 80GB 여러 장 필요
 - 학습 시간: 수일~수주
 - 비용: 수천만 원

PEFT (QLoRA)

- LoRA 파라미터만 업데이트 (0.1~1%)
 - T4 15GB 1장으로 가능
 - 학습 시간: 수십 분~수 시간
 - 비용: Colab 무료~수만 원

핵심 가치

- 저비용으로 sLLM 성능 보완
- 원본 모델 보존하며 도메인 특화
- Full FT 대비 90~98% 성능 유지

핵심 요약 및 마무리

LLM API의 한계

- 비용 증가: 대규모 사용 시 급증
- 데이터 보안: 외부 전송 필수
- 커스터마이징 불가: 모델 수정 불가능

sLLM의 장점

- 경량이면서 도메인 특화 시 충분한 성능
- 적은 리소스로 훈련 가능
- 내부 서버에서 안전하게 운영

자체 모델의 우위

- 대규모 서비스에서 비용 효율적
- 보안 규제 환경에서 유일한 선택지
- 반복 호출 비용 0원

PEFT의 역할

- QLoRA로 sLLM 성능 한계 보완
- 저비용으로 도메인 특화 가능
- 전체 파라미터의 0.1~1%만 학습

과정의 목표

- API 활용부터 sLLM 파인튜닝까지
- 실무 파이프라인 전체 구축
- 보안·비용·성능 모두 확보