

sLLM/SLM 파인튜닝 가이드

작지만 강력한 AI 모델의 세계

오픈소스 경량 언어모델부터 실전 파인튜닝까지, 기업과 개발자를 위한 완벽 가이드

2026 AI 교육 과정

목차

01 sLLM/SLM 개념과 특징

- LLM vs sLLM vs SLM 비교
- 각 모델의 특징점과 용도
- 하드웨어 요구사항
- 비용 효율성 분석

02 국내 오픈소스 sLLM 생태계

- EXAONE, SOLAR 시리즈
- 국가대표 AI 프로젝트
- HyperCLOVA X
- 기타 국내 모델 현황

03 해외 주요 오픈소스 모델

- Meta LLaMA, Google Gemma
- Microsoft Phi, Alibaba Qwen
- DeepSeek, Mistral AI
- 2025-2026 핵심 트렌드

04 HuggingFace 모델 허브

- 모델 허브 구조와 활용법
- 모델 카드 확인 항목
- 다운로드 및 실행 방법
- Ollama 로컬 실행

05 파인튜닝의 필요성과 방법

- 파인튜닝이 필요한 이유
- 사전학습 vs 파인튜닝
- LoRA/QLoRA 기법
- 학습 데이터 형식

06 실전 활용 전략

- 파인튜닝 vs RAG 비교
- 모델 크기별 용도 가이드
- 실무 최적 조합 전략
- 핵심 요약

학습 목표

오픈소스 sLLM/SLM 생태계 이해

- 현재 주요 오픈소스 모델들의 특징 파악
- LLM, sLLM, SLM의 차이점 이해
- 국내외 주요 모델 비교 분석
- 모델 크기별 적합한 용도 파악

국가대표 AI 프로젝트 현황 파악

- '독자 AI 파운데이션 모델' 프로젝트 이해
- 1차 평가 결과 및 선정 팀 현황
- 한국 AI 기술 주권 확보의 의미
- 글로벌 경쟁력 입증 사례

파인튜닝 개념과 필요성 이해

- 파인튜닝이 필요한 4가지 이유
- 사전학습과 파인튜닝의 차이
- LoRA/QLoRA 등 주요 기법 이해
- 학습 데이터 준비 방법

HuggingFace 모델 허브 활용

- 모델 허브의 구조와 핵심 기능
- 모델 카드 확인 필수 항목
- 모델 검색부터 배포까지 전체 흐름
- Ollama를 활용한 로컬 실행

sLLM이란?



sLLM 정의

수십억~수백억 개 파라미터의 경량 거대언어모델로, LLM보다 작은 규모이지만 효율적인 성능을 제공합니다.



주요 특징


LLM 대비 적은 리소스로 훈련 가능하며, 노트북이나 스마트폰 등 단말에서도 실행할 수 있는 높은 접근성을 갖추고 있습니다.



활용 트렌드

범용보다는 특정 요구사항을 충족하는 도메인 특화 활용이 주목받고 있으며, 기업 맞춤형 모델 구축에 최적화되어 있습니다.

sLLM의 주요 특징점




하드웨어 부담 감소

- 고가의 서버 구축 불필요
- 노트북, 스마트폰 등 단말에서도 실행 가능
- GPU 요구사항이 상대적으로 낮음
- 온프레미스 배포로 데이터 보안 강화

높은 비용 효율성

- 필요한 매개변수만 사용하여 학습시간 단축
- 운영 비용 대폭 절감
- 빠른 모델 훈련과 배포로 신속한 서비스 구축
- 사내 데이터 활용으로 맞춤형 모델 구축 및 데이터 유출 위험 감소



SLM이란?



SLM 정의

파라미터 10억 개 이하의 소형언어모델로, 제한된 컴퓨팅 자원에서도 효율적으로 운영 가능한 경량 모델입니다.



설계 철학

sLLM이 LLM을 축소한 것이라면, SLM은 애초에 소형으로 설계된 모델로 에너지 효율성과 빠른 응답 시간을 제공합니다.



최적 활용 분야

스마트 스피커, 셋탑박스, 홈서비스 로봇 등 소형기기에 최적화되어 있으며, 단순한 NLP 작업이나 제한된 도메인에서 주로 사용됩니다.

LLM vs sLLM vs SLM 비교

크기와 성능

- LLM: 매우 큼(수천억~수조)
- sLLM: 작음(수십억~수백억)
 - SLM: 아주 작음(≤ 10 억)
- 성능: LLM > sLLM(파인튜닝) > SLM

비용과 효율성

- LLM: 훈련·추론 비용 매우 높음
- sLLM: 상대적으로 저렴한 비용
- SLM: 최소 비용으로 운영 가능
 - 학습 시간: LLM(수개월) > sLLM(수일) > SLM(수시간)

배포와 활용

- LLM: 고성능 서버 필수, 복잡한 배포
- sLLM: 다양한 플랫폼 적합, 단순 배포
- SLM: 모바일·IoT 기기에서 즉시 실행
 - GPU 요구: LLM(다수) > sLLM(1~2개) > SLM(불필요)

대표적 특징


- LLM: 무엇이든 잘하는 만능형
- sLLM: 우리 업무에 딱 맞춘 전문가형
- SLM: 내 기기 안에서 돌아가는 경량형
- 일반화: LLM(최고) > sLLM(도메인 특화) > SLM(제한적)

국내 주요 오픈소스 sLLM - EXAONE 시리즈



EXAONE 3.5/Deep/4.0 시리즈

- EXAONE 3.5: 2.4B/7.8B/32B 파라미터, 한영 이중언어 지원
- 32K 컨텍스트, 20개 벤치마크에서 글로벌 최고 수준
- EXAONE Deep: 한국 최초 추론 특화 AI 모델
- EXAONE 4.0: 일반+추론 결합 하이브리드 모델
- EXAONE 4.0 VL: 멀티모달 (비전+언어) 지원



K-EXAONE (2026.01)

- 236B MoE 아키텍처 (23B 활성 파라미터)
- 256K 컨텍스트 윈도우, 6개 언어 지원
- Artificial Analysis 글로벌 7위 달성
- MTP 기술로 추론 속도 150% 향상
- KGC-Safety 한국형 안전 벤치마크 97.38점 (GPT-OSS-120B 92.48점 능가)



주요 특징점 및 성과

- 한영 이중언어 최적화로 한국어 성능 우수
- 온프레미스 배포 솔루션 제공
- Epoch AI Notable AI Models 5개 등재 (한국 기업 최다)
- 라이선스: EXAONE AI Model License (연구용 무료, 상업용 별도 문의)
- LG AI Research, 한국 오픈소스 sLLM 선두주자

국내 주요 오픈소스 sLLM - SOLAR 시리즈



SOLAR 10.7B 및 Solar Pro 시리즈

- SOLAR 10.7B: DUS(Depth Upscaling) 기법 적용, HuggingFace 리더보드 1~10위 석권
- Solar Pro: 22B 파라미터, 기업용 프라이빗 LLM 최적화



Solar Pro 2 (2025.07)


- 31B로 70B급 성능 구현; 하이브리드 모드·64K 토큰 지원; 글로벌 지표 12위·한국 최초 상위20



주요 특징점 및 라이선스

- Apache 2.0 라이선스(10.7B)
- Solar Pro 2: API 제공
- 한국어 벤치마크 최강·기업 최적화

국내 주요 오픈소스 sLLM - 기타 모델



네이버 HyperCLOVA X

- 한국어 최대 규모 학습 데이터 보유
- 경량 버전 HCX-DASH로 기업 업무 전반 지원
- 문장 생성·요약·보고서 작성·맞춤형 챗봇 기능
- 2026 수능 전과목 1등급 목표 옴니모달 모델 개발 중
- 비공개 라이선스 (API/대시 모델 제공)
- 온프레미스 배포 지원



SK텔레콤 A.X K1


- 500B 규모의 초거대 모델
- 글로벌 초거대 모델 경쟁 목표
- AI SOC (System on Chip) 역할 수행
- 국가대표 AI 프로젝트 2차 진출
- SK텔레콤의 AI 기술력 집약
- 통신·엔터프라이즈 분야 특화



NC AI 배키(VAETKI) 및 기타

- 배키(VAETKI): 100B급 멀티모달, 제조·국방·콘텐츠 산업 특화, GPU 사용량 83% 절감
- 삼성 Gauss: 사내 전용, 코드·언어·이미지 생성
- KT Mi:dm: 초거대 AI '믿음'(2100억)을 40~70억으로 경량화
- LG유플러스 ixi-GEN: EXAONE 기반 sLLM 서비스
- 모티프(Motif): 12.7B, 순수 국산 기술

국가대표 AI 프로젝트 개요

 '국가대표 AI' 5개 정예팀 참여 기업·대학 보니 자료: 과학기술정보통신부		
주관사	컨소시엄 참여사 기업·기관	과제 목표 및 방향
 네이버클라우드	네이버·트웰브랩스·서울대·카이스트·포스텍·고려대·한양대	범국민 AI 접근성 확대를 위한 옴니(Omni) 파운데이션 모델 구축
 업스테이지	노타·래블업·플리토·로앤컴퍼니·데이원컴퍼니·금융결제원·서강대 등	글로벌 프런티어 수준 모델 개발 및 법률·의료 등 B2B 서비스 확산
 SK텔레콤	크래프톤·포티투닷·리벨리온·라이너·셀렉트스타·서울대·카이스트	차세대 트랜스포머 기반 초거대 모델 개발 및 K-AI 서비스 구현
 NC AI	NHN·포스코DX·롯데이노베이트·MBC·서울대·고려대·연세대·카이스트 등	제조·유통·콘텐츠 등 산업용 멀티모달 파운데이션 모델 개발
 LG AI연구원	LG유플러스·LG CNS·퓨리오사AI·이스트소프트·한글과컴퓨터·뤼튼테크놀로지스 등	전문성·범용성 갖춘 글로벌 최고 수준 프런티어 모델 K-EXAONE 개발

프로젝트 목표 및 배경

- 이재명 정부 'AI 3대 강국 도약' 핵심 공약
- GPT·Gemini 등 글로벌 AI 모델 95% 이상 성능 확보 목표
- 한국형 독자 AI 파운데이션 모델 개발
- 글로벌 톱10 수준의 모델 확보 지향

정부 지원 및 추진 방향

- 정부의 GPU·데이터·인재 지원
- 엔비디아, 한국에 총 26만장 GPU 투입 발표 (최대 14조원 규모)
- 한국 AI 기술 주권 확보 및 해외 종속 극복
- 공공·경제·사회 분야 AX(AI 전환) 가속화

국가대표 AI 1차 평가 결과

LG AI연구원 (전 부문 1위)

- K-EXAONE (236B MoE) 개발
- 벤치마크 평가 33.6점으로 최고점
- 전문가 평가·사용자 평가 모두 1위
- 2차 진출 확정

업스테이지 & SK텔레콤

- 업스테이지: 솔라 오픈100B (100B MoE) 2차 진출
- SK텔레콤: A.X K1 (500B) 2차 진출
- 두 팀 모두 종합 평가에서 우수한 성적
- 한국 AI 기업의 기술력 입증

모티프테크놀로지스 추가 선정

- 2026.02.20 추가 선정으로 총 4팀 경쟁 체제
- 모티프(Motif) 12.7B 모델
- 순수 국산 기술로 구축~학습 전 과정 수행
- 다양성 확보로 경쟁력 강화

전체 성과 및 의의

- 5개 팀 모델 전부 Epoch AI Notable AI Models 등재
- 벤치마크(40점)+전문가(35점)+사용자(25점) 평가
- 대한민국 AI 기술 주권 확보의 국가적 도전
- K-AI 모델 통한 공공·경제·사회 AX 가속

Meta LLaMA 시리즈



LLaMA 3.1

- 8B/70B/405B 파라미터 제공
- 범용 성능 최강, 가장 널리 사용되는 오픈소스 모델



LLaMA 4


- Scout 109B(17B 활성), Maverick 400B(17B 활성)
- MoE 아키텍처 도입으로 효율성 극대화



커뮤니티 생태계

- 가장 큰 오픈소스 커뮤니티 보유
- 파인튜닝 변형 모델 수천 개, Llama License (조건부 상업 이용)

Google Gemma 4



Gemma 4 E2B/E4B

- ~2B/~4B (Effective)
- 엣지·모바일 최적화
- 오디오 입력 지원
- 온디바이스 실행 가능
- 높은 추론력 제공



Gemma 4 26B A4B

- 26B (MoE, 4B 활성화)
- MoE 효율성 극대화
- 31B 근접 성능 달성
- 활성화 파라미터 적으면서
- 동급 Dense 모델 성능



Gemma 4 31B

- 31B (Dense) 플래그십
- Arena AI 텍스트 3위
- 256K 토큰 컨텍스트
- 140개 이상 언어 지원
- 네이티브 비전·오디오
- Apache 2.0 라이선스

Microsoft Phi-4



Phi-4 (14B)

- 수학·복잡한 추론에서 훨씬 큰 모델 능가
- 데이터 품질 중심 훈련으로 파라미터 대비 최고 성능 달성



Phi-4-mini (3.8B)


- 128K 토큰 컨텍스트 지원
- Function Calling 지원, 200K 어휘, 온디바이스 실행 최적화



Phi-4-multimodal (5.6B)


- 텍스트+음성+비전 단일 아키텍처 처리
- MIT 라이선스로 완전 자유 상업 이용 가능

Alibaba Qwen 3/3.5



Qwen3 Dense

- 0.6B~32B 파라미터
- 하이브리드 추론 모드
- /think, /no_think로
- 실시간 전환 가능
- 119개 언어 지원



Qwen3 MoE

- 30B-A3B/235B-A22B
- 활성 파라미터 10%로
- 동급 Dense 성능 달성
- 효율적 MoE 설계
- 36조 토큰 학습



Qwen3.5 & Coder


- 397B-A17B 외 다수
- 201개 언어 지원
- 네이티브 멀티모달
- Coder: 480B-A35B
- 코드 특화, 무료 제공
- Apache 2.0 라이선스

DeepSeek & Mistral



DeepSeek V3/R1

- DeepSeek V3: 671B (37B 활성), MoE 아키텍처
- DeepSeek R1: 추론 특화, 수학·과학 벤치마크 최고 수준
- R1 Distill 시리즈: 1.5B~70B 경량 증류 버전
- 코딩·추론 최상위 성능, DeepSeek License



Mistral AI

Mistral AI 시리즈

- Mistral 7B: MoE 아키텍처의 선구자
- Mixtral 8x7B: 46.7B (12.9B 활성), 코딩·수학 강점
- Mixtral 8x22B: 176B (39B 활성), 대형 MoE
- 유럽 기반, Apache 2.0 라이선스로 자유로운 상업 이용

2025~2026 핵심 트렌드



MoE 보편화

- Qwen3, DeepSeek V3, K-EXAONE, LLaMA 4 등 최신 모델 채택
- 전체 파라미터는 크지만 실제 활성 파라미터는 작게 유지



하이브리드 추론


- Qwen3, Solar Pro 2, EXAONE 4.0, Phi-4-reasoning 도입
- 빠른 응답(챗 모드)과 깊은 사고(추론 모드) 사용자 선택 가능



효율적 설계 표준

- 대부분의 최신 모델이 MoE 아키텍처 채택
- 효율적 설계가 업계 표준으로 자리잡음

2025~2026 핵심 트렌드 (2)



멀티모달의 기본화

- SLM급에서도 텍스트+이미지+오디오가 표준으로 자리잡음
- Gemma 4, Phi-4-multimodal, Qwen3.5 등이 네이티브 멀티모달 지원
- 단일 아키텍처로 다양한 입력 형식을 처리하는 것이 새로운 기본값
- 음성 인식, 이미지 이해, 텍스트 생성을 하나의 모델로 통합

한국 모델의 글로벌 경쟁력 입증

- K-EXAONE이 Artificial Analysis 글로벌 7위 달성
- Solar Pro 2가 글로벌 12위로 한국 LLM 최초 상위 20위 진입
- 국가대표 AI 프로젝트를 통한 한국 AI 기술 주권 확보 본격화
- 5개 팀 모델 전부 Epoch AI Notable AI Models 등재

모델 크기별 용도 가이드

1B~3B 파라미터

- 필요 GPU 메모리: 2~4GB
- 적합 용도: 모바일·IoT 기기
- 단순 분류, 요약 작업
- 스마트폰에서도 실행 가능한 경량 모델

7B~8B 파라미터

- 필요 GPU 메모리: 4~8GB
- 적합 용도: 범용 챗봇, 문서 요약, 코드 보조
- 노트북 GPU에서도 추론 가능
- 대부분의 기업 업무에 충분한 성능 제공

13B~14B 파라미터

- 필요 GPU 메모리: 8~12GB
- 적합 용도: 고품질 한국어 생성
- 복잡한 추론 작업 처리
- 전문적인 문서 작성 및 분석

27B~32B 파라미터

- 필요 GPU 메모리: 16~24GB
- 적합 용도: 기업 내부 전용 서비스
- 전문 도메인 QA 시스템
- 대규모 엔터프라이즈급 응용

HuggingFace 모델 허브란?



플랫폼 개요

- 오픈소스 AI 모델의 공유·배포 플랫폼
- AI 분야의 GitHub라고 불림
- 전 세계 연구자와 기업이 학습한 모델을 공개
- 누구나 무료로 다운로드하여 자사 환경에 배포 가능
- <https://huggingface.co> 에서 접근



핵심 구성 요소

- Models: 100만 개 이상의 사전학습·파인튜닝 모델
- Datasets: 25만 개 이상의 공개 학습 데이터셋
- Spaces: 모델 웹 데모 앱 호스팅 서비스
- Model Card: 성능, 학습 데이터, 라이선스 문서
- Open LLM Leaderboard: 벤치마크 성능 비교



활용 가치

- 검증된 모델을 빠르게 찾아 활용 가능
- 커뮤니티의 다운로드 수와 좋아요로 품질 확인
- 다양한 라이선스 옵션으로 상업적 이용 가능
- 파인튜닝 변형 모델 수천 개 제공
- 실무 적용을 위한 최적의 출발점

모델 카드 확인 핵심 항목

라이선스

- 상업적 이용 가능 여부 확인
- Apache 2.0, MIT: 자유로운 상업 이용
- Llama License: 조건부 이용

모델 크기

- 파라미터 수 확인 필수
- GPU 메모리 요구사항 검토
- 우리 서버에 맞는지 확인
- 양자화 버전 존재 여부

지원 언어

- 한국어가 학습 데이터에 포함되었는지
- 한국어 비중 확인 중요
- 다국어 지원 범위 검토

기타 확인 사항

- 벤치마크 성능 점수 비교
- 다운로드 수와 좋아요 확인
- 커뮤니티 검증 지표
- Model Card 상세 문서 검토

HuggingFace 모델 활용 흐름

1단계: 검색

- HuggingFace에서 모델 검색
 - Model Card 확인
 - 용도에 맞게 모델 선택

2단계: 검토

- 라이선스 확인
- 성능 지표 검토
- 모델 크기 확인
- 다운로드 진행

3단계: 테스트

- 로컬에서 추론 테스트
- transformers 라이브러리 사용
 - 성능 평가


4단계: 파인튜닝

- 우리 데이터로 파인튜닝
- QLoRA 등 효율적 방법 사용
 - 도메인 특화

5단계: 배포

- 실제 서비스에 배포
- Ollama로 간편 실행
 - 운영 환경 구축

파인튜닝이 필요한 이유 (1)




문제 1: 도메인 지식 부족


- 범용 모델은 우리 회사의 상품·정책을 모름
- 예: '당사의 플러스 정기예금 상품의 우대금리 조건을 알려줘' 질문에 답변 불가
- 사내 전문 용어와 업무 프로세스를 이해하지 못함
- 특정 산업 도메인의 전문 지식이 부족함

문제 2: 응답 스타일 불일치

- 고객 응대에 맞는 존댓말 사용이 일관되지 않음
- 회사의 톤앤매너에 맞지 않는 답변 생성
- 공식 문서 작성 스타일과 불일치
- 범용 모델을 그대로 쓰면 업무 적용에 한계 발생



파인튜닝이 필요한 이유 (2)



파인튜닝 모델 평가

한국어 LLM 파인튜닝

문제 3: 한국어 성능 부족

- 대부분의 오픈소스 모델은 영어 중심으로 학습됨
- 한국어 학습 데이터 비율이 매우 낮음 (예: Llama 2는 0.06%)
- 한국어 이해와 생성 능력이 제한적
- 한국어 특화 파인튜닝으로 성능 향상 가능

문제 4: 할루시네이션

- 학습하지 않은 내용을 그럴듯하게 지어내는 현상
- 사실이 아닌 정보를 자신있게 제시
- 파인튜닝으로 도메인 전문가로 전환 가능
- RAG와 결합하여 사실 기반 응답 강화

사전학습 vs 파인튜닝



사전학습 (Pre-training)

- 목적: 언어 자체를 학습
- 데이터: 인터넷 전체 텍스트 (수조 토큰)
- 비용: 수십억~수천억 원
- 시간: 수주~수개월
- 주체: 대기업·연구기관
- 결과: 범용 언어 모델 구축
- 요구사항: 고성능 GPU 클러스터 필수
- 특징: 대규모 인프라와 자원 필요



파인튜닝 (Fine-tuning)

- 목적: 특정 도메인·업무에 맞게 조정
- 데이터: 우리 회사 데이터 (수천~수만 건)
- 비용: 수십만~수백만 원
- 시간: 수시간~수일
- 주체: 누구나 가능
- 결과: 맞춤형 전문 모델 구축
- 요구사항: GPU 1~2장이면 충분
- 특징: 효율적이고 실용적인 접근

파인튜닝의 종류

Full Fine-tuning

- 모델 전체 파라미터를 재학습
- 대규모 학습 데이터 필요
- GPU 요구: 높음 (A100 다수)
- 최고 성능 달성 가능

LoRA / QLoRA

- 전체 파라미터 중 일부 어댑터만 학습
- 소규모 데이터로 가능 (수천 건~)
- GPU 요구: 낮음 (단일 GPU 가능)
- 실무에서 가장 많이 사용되는 방식


RLHF / DPO

- 인간 피드백 기반 선호도 학습
- 선호도 쌍 데이터 활용
- GPU 요구: 중간
- 응답 품질 개선에 효과적

Prompt Tuning

- 프롬프트 임베딩만 학습
- 최소한의 데이터 필요
- GPU 요구: 최소
- 빠른 적응이 필요한 경우 적합

파인튜닝 학습 데이터 형식



파인튜닝에 필요한 데이터는 질의-응답 쌍(instruction-response pair) 형태로 구성됩니다. 이러한 데이터를 수백~수천 건 준비하면 우리 업무에 특화된 도메인 전문 sLLM을 구축할 수 있습니다. 예를 들어 회사 상품 가격, 지점별 매출, 고객 응대 매뉴얼 등을 학습시켜 실무에 바로 활용 가능한 AI 모델을 만들 수 있습니다.

파인튜닝 vs RAG



파인튜닝 (Fine-tuning)

- 목적: 모델의 행동과 지식 자체를 변경
- 업데이트: 데이터 변경 시 재학습 필요
- 적합한 경우: 응답 스타일 통일, 도메인 전문 용어, 한국어 강화
 - 장점: 모델에 지식이 내재화됨
 - 단점: 정보 업데이트가 느림
- 활용: 톤앤매너, 전문 용어, 업무 프로세스 학습



RAG (검색 증강 생성)

- 목적: 외부 문서를 검색해서 답변에 참고
- 업데이트: 문서 업데이트만으로 즉시 반영
- 적합한 경우: 자주 바뀌는 정보 (가격, 정책, 공지사항)
 - 장점: 실시간 정보 반영 가능
 - 단점: 검색 시스템 구축 필요
- 활용: 최신 정보, 규정, 가격표, 공지사항

핵심 요약

- 오픈소스 sLLM 생태계는 국외·국내 모두 성숙, 한국 AI 주권 확보 진행
 - 2025~2026 핵심 트렌드: MoE 보편화·하이브리드 추론·멀티모달·한국 모델 경쟁력
 - HuggingFace는 100만+ 모델 검색·다운로드 플랫폼
 - QLoRA로 단일 GPU에서도 맞춤형 sLLM 구축 가능
-