

API 파라미터 실험

temperature · max_tokens · top_p

LLM 응답 품질을 결정하는 핵심 파라미터의 이해와 실전 활용

LLM 파라미터 튜닝 실습 과정

목차

01 학습 목표

- 단일 변수 실험 원칙 이해
- 파라미터별 응답 변화 관찰
- 태스크별 적정값 도출

02 실험 설계 원칙

- 왜 실험 설계가 중요한가
- 실험 4원칙
- 파라미터 전체 지도

03 temperature 파라미터

- 확률 분포의 날카로움
- 값별 효과와 권장 태스크
- 환각 위험성 이해

04 max_tokens 파라미터

- 응답 길이 제어 개념
- finish_reason 이해
- 태스크별 권장값

05 top_p 파라미터

- 누클리어스 샘플링 개념
- temperature와의 관계
- 조합 권장 사항

06 종합 정리 및 활용

- 파라미터 효과 요약
- Day별 사용 계획
- 실습 체크포인트

학습 목표

실험 설계

- 단일 변수 실험 원칙 이해
- 실험을 설계할 수 있다

temperature

- 값에 따른 응답 변화 관찰
- 태스크별 적정 값 판단

max_tokens

- 응답 잘림 현상 확인
- 원인을 설명할 수 있다

top_p

- 개념과 temperature 관계
- 역할 차이를 설명할 수 있다

실험 결과

- 결과를 기록표에 정리
- 법률 Q&A 적합 조합 도출

실험 설계 원칙 — 왜 중요한가



한 번에 하나의 변수만 변경하는 이유

- 어떤 파라미터가 응답을 바꿨는지 명확히 파악 가능
- 좋은 실험은 한 번에 하나의 변수만 변경



여러 파라미터 동시 변경 시 문제점

- 원인 파악 불가
- 질문 차이로 결과 오염
- 우연한 결과 일반화 위험



LLM 파라미터 튜닝과 파인튜닝의 공통점

- 단일 변수 실험 원칙은 동일하게 적용
- Day 4 파인튜닝 하이퍼파라미터 실험에서도 필수

실험 4원칙

단일 변수

- 한 번에 하나의 파라미터만 변경
- 위반 시: 변화 원인 파악 불가

동일 질문

- 질문은 고정, 파라미터만 변경
- 위반 시: 질문 차이로 결과 오염

반복 실행

- 같은 설정으로 2-3회 실행해 변동 폭 확인
- 위반 시: 우연한 결과를 일반화할 위험

기록

- 결과를 직접 비교할 수 있도록 출력 형태 통일
- 위반 시: 주관적 비교에 그침

파라미터 전체 지도 — 역할 분류



무엇을 말할지

- messages (system/user)
- 답변 내용·주제·형식 결정
- 응답의 방향성 설정



어떻게 말할지

- temperature, top_p
- 답변의 다양성·창의성 조절
- 토큰 선택 방식 결정
- 확률 분포 조절



얼마나 말할지

- max_tokens
- 답변 길이 상한선 설정
- 언제 멈출지 결정
- 도달 시 강제 중단

temperature 개념 — 확률 분포의 날카로움

LLM의 토큰 선택 방식

- LLM은 다음 토큰을 확률 분포에서 샘플링하여 선택
- temperature는 확률 분포의 날카로움을 조절하는 파라미터
- 응답의 다양성과 창의성을 결정하는 핵심 요소

낮은 temperature 효과

- 확률이 높은 토큰에 집중
- 항상 비슷한 응답 생성
- 일관적이고 예측 가능한 결과
- 예: 매일 같은 식당만 간다

높은 temperature 효과

- 확률이 고르게 분산
- 다양하고 예측 불가능한 응답
- 창의적이지만 환각 위험 증가
- 예: 눈 감고 아무 데나 들어간다

식당 선택 비유

- 0.0: 매일 같은 식당 (김치찌개집)
- 0.3: 보통 같은 동네 (가끔 된장찌개)
- 0.7: 새로운 곳 시도 (이탈리안, 쌀국수)
- 1.5: 아무 데나 (곤충식 레스토랑)

temperature 값별 효과와 권장 태스크

0.0 — 완전 결정론적

- 동일 입력 = 동일 출력
- 권장: 데이터 추출, JSON 생성, 분류
- 비권장: 창의적 글쓰기
- 완전히 예측 가능한 응답

0.1-0.3 — 매우 일관적

- 약간의 변동만 존재
- 권장: 법률·의료 답변, 요약
- 비권장: 아이디어 브레인스토밍
- 정확성과 일관성 확보

0.7-1.0 — 창의적·다양

- 매번 조금씩 다른 응답
- 권장: 글쓰기, 아이디어 생성, 대화
- 비권장: 정확한 수치 추출
- 자연스러운 다양성

1.5-2.0 — 매우 무작위

- 때로 비문 발생
- 권장: 실험적 창작
- 비권장: 실무 전반
- 환각 위험 매우 높음
- 없는 법조문 인용 가능

실험 1-A — temperature 4단계 실험

temperature 0.0

- 3번 실행해도 동일한 응답
- 정형화된 3가지 요소 나열
 - 어휘 선택 매우 제한적
 - 사실 정확도 가장 높음
 - 법률 Q&A 적합도 높음

temperature 0.5

- 위와 비슷하지만 표현 약간 달라짐
- 일관성 유지하면서 자연스러움
 - 어휘 다양성 적절
 - 사실 정확도 높음
 - 법률 Q&A 적합

temperature 1.0

- 새로운 관점 추가
- 매번 다른 구성
- 어휘 다양성 풍부
- 사실 정확도 약간 낮아질 수 있음
- 창의적 태스크 적합

temperature 1.5

- 관련 없는 내용 등장 가능
- 없는 법조문 인용 위험
- 문장 부자연스러울 수 있음
 - 환각 현상 빈번
 - 법률 Q&A 부적합

같은 질문, 다른 답 — 문제 vs 장점



문제가 되는 경우 — 일관성이 중요한 도메인

- 법률: 다른 법조문 인용 시 신뢰 하락
- 의료: 동일 증상에 다른 진단은 위험
- 금융: 다른 이율 안내로 법적 문제
- 데이터 추출: JSON 불일치로 파싱 실패



장점이 되는 경우 — 다양성이 가치인 도메인

- 창의적 글쓰기: 다양한 비유와 문체
- 아이디어 생성: 여러 관점 확보 (5회→5접근)
- 대화 챗봇: 자연스러운 대화
- 합성 데이터: 다양한 Q&A 필요



환각(Hallucination)의 위험성

- temperature ↑ → 비사실적 생성 증가
- 0.0-0.3: 드뭇, 0.7-1.0: 가끔, 1.5: 빈번
- 존재하지 않는 판례·용어 인용 위험
- 파인튜닝으로 환각 감소 가능

max_tokens — 응답 길이 제어

개념 — 최대 토큰 수 상한선

- 모델이 생성하는 최대 토큰 수 제한
- '이만큼 생성하라'가 아닌 '이 이상은 생성하지 마라'
- 상한 도달 시 문장 중간이라도 강제 종료
- 응답 길이의 상한선 역할

finish_reason: stop vs length

- stop: 모델이 자연스럽게 종료 (정상)
- length: 상한 도달로 강제 중단
- 30 토큰: 문장 중간 잘림, finish_reason: length
- 300 토큰: 완전한 응답, finish_reason: stop




태스크별 권장값

- 한 줄 요약: 50-100
- 단락 설명: 200-400
- Judge(JSON): 300-500
- 상세 분석: 500-1,000
- 긴 문서: 1,000-4,000

주의사항 — JSON 파싱 실패

- Day 2 Judge 평가에서 JSON 반환 시 주의
- max_tokens 낮으면 JSON 중간에 잘림
- json.loads() 파싱 실패로 이어짐
- Judge 함수는 반드시 300 이상 설정

top_p — 누클리어스 샘플링



개념

- 누적 확률 상위 p% 안의 토큰만 후보로 선택
- top_p=0.9: 누적 90% 도달까지만 포함
- 확률 낮은 이상한 토큰 원천 차단
- 0.5: 매우 보수적 어휘
- 0.9: 적절한 다양성
- 1.0: 모든 토큰 후보

temperature와의 비교

- temperature: 확률 분포 전체의 평탄도 조절 (주사위 눈 확률 변경)
- top_p: 후보 토큰 풀 크기 제한 (주사위 눈 개수 감소)
- 서로 다른 방식으로 다양성 조절
- 동시 조절 시 효과 겹쳐 원인 파악 어려움

실무 권장 조합

- temperature만 조절하고 top_p=0.9 고정
- 이번 과정 전체에서 top_p=0.9 사용
- temperature 낮음 + top_p 높음: 사실형 태스크
- temperature 높음 + top_p 높음: 창의형 태스크
- 단일 변수 실험 원칙 준수

파라미터 종합 정리 및 Day별 사용 계획

- temperature: 응답 다양성 조절 (기본값 0.3)
 - max_tokens: 응답 길이 상한 설정 (태스크별 조정)
 - top_p: 후보 토큰 범위 제한 (고정값 0.9)
 - Day별로 태스크 특성에 맞춰 파라미터를 전략적으로 조합하여 최적의 결과를 도출합니다
-